

KHOA TOÁN KINH TẾ



MÔN HỌC: ĐÁNH GIÁ TÍN DỤNG

TIỂU LUẬN CUỐI KỲ

GVHD: TS. Lê Thị Thanh An

SVTH: Lê Thị Phương Trinh

MSSV: K234131517

MỤC LỤC

PHẦN 1. LÝ THUYẾT	2
1.1. Giải thích vai trò của 5 chữ C (Character, Capacity, Capital, Collateral, Conditions) trong quy trình đánh giá tín dụng truyền thống.....	2
1.2. Phân tích sự chuyển dịch từ phương pháp đánh giá định tính (Judgmental) sang phương pháp đánh giá định lượng (Empirical Scoring). Tại sao việc “công nghiệp hóa sự tin cậy” lại trở nên thiết yếu trong kỷ nguyên tài chính số?.....	3
PHẦN 2. KIỂM TRA VÀ XỬ LÝ DỮ LIỆU	5
2.1. Kiểm tra chất lượng dữ liệu	5
2.2. Xử lý lỗi định dạng và lỗi logic nhập liệu.....	5
2.3. Xử lý dữ liệu thiếu.....	5
2.4. Xử lý giá trị ngoại lai	6
2.5. Xử lý mất cân bằng dữ liệu	6
PHẦN 3. XÂY DỰNG ĐẶC TRƯNG VÀ LỰA CHỌN BIẾN	7
3.1. Xây dựng biến mới.....	7
3.2. Mã hóa biến hạng mục.....	7
3.3. Lựa chọn biến.....	8
PHẦN 4. XÂY DỰNG VÀ SO SÁNH CÁC MÔ HÌNH	8
4.1. Nhóm mô hình truyền thống.....	8
4.2. Nhóm mô hình phi truyền thống	9
4.3. So sánh hiệu suất mô hình.....	10
4.4. Tinh chỉnh siêu tham số.....	11
PHẦN 5. DỰ BÁO NGOÀI MẪU VÀ GIẢI THÍCH BẰNG SHAP	12
5.1. Dự báo ngoài mẫu	12
5.2. Giải thích bằng SHAP.....	13
TÀI LIỆU THAM KHẢO	15

PHẦN 1. LÝ THUYẾT

1.1. Giải thích vai trò của 5 chữ C (Character, Capacity, Capital, Collateral, Conditions) trong quy trình đánh giá tín dụng truyền thống.

Trong quy trình đánh giá tín dụng truyền thống, mô hình 5C không nên được hiểu như một danh sách các tiêu chí độc lập mà cần được nhìn nhận như một hệ thống bổ sung lẫn nhau, trong đó mỗi chữ C bù đắp cho những giới hạn của các chữ C còn lại. Sở dĩ mô hình tồn tại bền vững qua nhiều thập kỷ trong hoạt động ngân hàng, ngay cả khi các mô hình chấm điểm tín dụng định lượng và trí tuệ nhân tạo ngày càng phổ biến, là vì nó phản ánh một nguyên lý cơ bản của quản trị rủi ro tín dụng, đó là rủi ro không thể được đo lường đầy đủ chỉ bằng con số mà còn phụ thuộc vào các yếu tố hành vi và bối cảnh khó lượng hóa [1].

So sánh Character và Capacity có thể thấy đây là hai yếu tố thường được xem là quan trọng nhất nhưng lại đo lường hai khía cạnh hoàn toàn khác nhau của rủi ro. Character phản ánh thiện chí trả nợ, tức yếu tố mang tính đạo đức và hành vi, trong khi Capacity phản ánh năng lực trả nợ, tức yếu tố mang tính tài chính và định lượng. Một khách hàng có thể có Character rất tốt, thể hiện qua lịch sử tín dụng sạch và uy tín cao, nhưng nếu dòng tiền hiện tại không ổn định do mất việc làm hoặc doanh nghiệp suy giảm doanh thu thì Capacity vẫn thấp, và khoản vay vẫn tiềm ẩn rủi ro cao. Ngược lại, một doanh nghiệp có dòng tiền dồi dào nhưng từng có lịch sử chậm trả nợ hoặc tranh chấp pháp lý sẽ khiến ngân hàng e ngại dù năng lực tài chính không phải là vấn đề. Chính vì hai yếu tố này không thể thay thế nhau mà Mishkin (2016) nhấn mạnh rằng các tổ chức tín dụng cần đánh giá đồng thời cả hai để tránh sai lầm chọn lọc bất lợi (adverse selection), tức tình trạng cấp tín dụng cho những khách hàng có rủi ro cao hơn mức mà ngân hàng nhận thức được.

Capital và Collateral cũng thường bị nhầm lẫn là giống nhau vì cả hai đều liên quan đến tài sản, nhưng thực chất chúng đóng vai trò khác biệt trong cấu trúc bảo vệ rủi ro. Capital là phần vốn tự có mà người đi vay đã đầu tư trước khi tiếp cận khoản vay, thể hiện mức độ cam kết và khả năng gánh chịu tổn thất ngay từ đầu, trong khi Collateral là tài sản bảo đảm được thế chấp cho riêng khoản vay đó và chỉ có ý nghĩa khi xảy ra vỡ nợ. Nói cách khác, Capital là lớp phòng thủ chủ động của bản thân người vay, còn Collateral là lớp phòng thủ thụ động dành cho ngân hàng. Một dự án được tài trợ với tỷ lệ vốn tự có cao nhưng tài sản bảo đảm yếu vẫn có thể được chấp thuận, vì tỷ lệ vốn tự có cao cho thấy người vay có động lực mạnh để dự án thành công, đúng như lý thuyết về vấn đề đại diện trong tài chính doanh nghiệp mà Rose và Hudgins (2013) đã đề cập, theo đó việc chủ sở hữu bỏ vốn càng nhiều thì xung đột lợi ích giữa người vay và người cho vay càng giảm.

Trong khi bốn chữ C đầu tiên tập trung vào đặc điểm nội tại của người vay, Conditions đóng vai trò như một biến số điều chỉnh mang tính hệ thống, phản ánh rủi ro đến từ môi trường bên ngoài mà bản thân người vay không kiểm soát được. Điều này tạo ra một sự khác biệt căn bản so với bốn yếu tố còn lại, bởi Conditions không đánh giá bản thân khách hàng mà đánh giá bối cảnh mà khoản vay đó tồn tại. Chẳng hạn, hai doanh nghiệp có Character, Capacity, Capital và Collateral tương đương nhau nhưng hoạt động trong hai ngành khác nhau, một ngành đang tăng trưởng và một ngành đang suy thoái, sẽ được ngân hàng đánh giá rủi ro rất khác nhau. Chính yếu tố Conditions giúp lý giải tại sao trong giai đoạn khủng hoảng kinh tế hoặc khi lãi suất biến động mạnh, ngân hàng thường siết chặt điều kiện cấp tín dụng ngay cả với những khách hàng có hồ sơ tốt, vì rủi ro hệ thống lúc này lấn át rủi ro cá biệt (Mishkin, 2016).

Một điểm đáng lưu ý khi liên hệ mô hình 5C với thực tiễn hiện đại là các phương pháp chấm điểm tín dụng định lượng, chẳng hạn như mô hình điểm Z của Altman hay các mô hình xếp hạng tín dụng nội bộ theo chuẩn Basel, thực chất không thay thế mà chỉ lượng hóa lại các yếu tố trong 5C dưới dạng biến số thống kê. Capacity được lượng hóa qua các hệ số như tỷ lệ nợ trên thu nhập hoặc tỷ lệ khả

năng trả nợ, Capital được thể hiện qua tỷ lệ vốn chủ sở hữu trên tổng tài sản, còn Character dần được thay thế bằng điểm tín dụng định lượng dựa trên lịch sử thanh toán. Tuy nhiên, sự khác biệt căn bản là các mô hình định lượng hiện đại xử lý dữ liệu theo phương pháp thống kê hàng loạt, còn 5C vẫn giữ vai trò là khung tư duy định tính cho phép cán bộ tín dụng đưa ra phán đoán trong những trường hợp đặc thù mà mô hình thống kê không bao quát hết, chẳng hạn như doanh nghiệp mới thành lập chưa có đủ dữ liệu lịch sử. Do đó, phần lớn ngân hàng hiện nay áp dụng cách tiếp cận kết hợp, trong đó 5C được dùng như bước sàng lọc định tính ban đầu trước khi đưa vào các mô hình chấm điểm định lượng chi tiết hơn [2].

Giá trị thực sự của mô hình 5C không nằm ở việc liệt kê năm tiêu chí riêng biệt mà nằm ở cách các tiêu chí này tương tác và bù trừ cho nhau để tạo thành một bức tranh rủi ro đa chiều. Character và Capacity cùng đánh giá con người và dòng tiền nhưng từ hai góc độ đạo đức và tài chính khác nhau, Capital và Collateral cùng tạo lớp đệm bảo vệ nhưng theo hai cơ chế chủ động và thụ động khác nhau, còn Conditions đóng vai trò như một biến số điều chỉnh toàn cục vượt ra ngoài bản thân người vay. Chính sự phối hợp đa tầng này giải thích tại sao mô hình 5C, dù ra đời từ rất sớm trong lịch sử ngân hàng, vẫn tiếp tục là nền tảng tư duy cho cả các mô hình quản trị rủi ro tín dụng hiện đại ngày nay [1].

1.2. Phân tích sự chuyển dịch từ phương pháp đánh giá định tính (Judgmental) sang phương pháp đánh giá định lượng (Empirical Scoring). Tại sao việc “công nghiệp hóa sự tin cậy” lại trở nên thiết yếu trong kỷ nguyên tài chính số?

Trong lịch sử phát triển của hoạt động tín dụng ngân hàng, phương pháp đánh giá định tính, thường được gọi là judgmental lending hay phương pháp thẩm định theo phán đoán chuyên gia, từng là nền tảng gần như duy nhất để ra quyết định cấp tín dụng. Trong phương pháp này, cán bộ tín dụng đóng vai trò trung tâm, sử dụng kinh nghiệm cá nhân, hiểu biết về khách hàng và các mối quan hệ được tích lũy qua thời gian để đánh giá năm chữ C đã trình bày ở phần trên. Cách tiếp cận này gắn liền với khái niệm mà Petersen và Rajan (1994) gọi là relationship lending, tức cho vay dựa trên quan hệ, trong đó ngân hàng thu thập thông tin mềm, tức những thông tin khó lượng hóa như tính cách, thái độ, uy tín trong cộng đồng kinh doanh và mức độ minh bạch của người vay thông qua tiếp xúc trực tiếp và lặp lại nhiều lần. Ưu điểm của phương pháp định tính nằm ở khả năng nắm bắt những khía cạnh tinh tế của rủi ro mà dữ liệu số không thể phản ánh đầy đủ, đặc biệt đối với các doanh nghiệp nhỏ hoặc khách hàng chưa có lịch sử tín dụng chính thức. Tuy nhiên, chính sự phụ thuộc vào phán đoán cá nhân cũng khiến phương pháp này bộc lộ nhiều hạn chế nghiêm trọng, bao gồm tính thiếu nhất quán giữa các cán bộ thẩm định khác nhau, nguy cơ thiên lệch chủ quan và thiên vị, chi phí vận hành cao do đòi hỏi nhiều thời gian và nhân lực có kinh nghiệm, cũng như khả năng mở rộng quy mô rất hạn chế khi số lượng khách hàng tăng lên nhanh chóng.

Sự chuyển dịch sang phương pháp đánh giá định lượng, hay còn gọi là empirical scoring hoặc credit scoring, bắt đầu được thúc đẩy mạnh mẽ từ giữa thế kỷ hai mươi, đặc biệt sau khi Bill Fair và Earl Isaac phát triển các mô hình chấm điểm tín dụng thương mại đầu tiên, đặt nền móng cho ngành công nghiệp chấm điểm tín dụng hiện đại mà công ty FICO sau này kế thừa. Về bản chất học thuật, credit scoring là việc áp dụng các mô hình thống kê, ban đầu là phân tích phân biệt tuyến tính, sau đó phát triển thành hồi quy logistic và các kỹ thuật học máy phức tạp hơn, nhằm lượng hóa xác suất vỡ nợ dựa trên một tập hợp các biến số quan sát được từ dữ liệu lịch sử của một lượng lớn khách hàng. Thomas, Edelman và Crook (2002), trong công trình kinh điển về ứng dụng credit scoring, đã chỉ ra rằng giá trị cốt lõi của phương pháp định lượng không nằm ở việc dự đoán chính xác hành vi của một cá nhân cụ thể mà nằm ở việc phân loại thống kê một nhóm lớn khách hàng có đặc điểm tương tự vào các mức rủi ro khác nhau, từ đó cho phép ngân hàng quản trị rủi ro danh mục một cách có hệ thống thay vì chỉ dựa vào từng trường hợp riêng lẻ.

Nếu đặt hai phương pháp này trong thế đối lập, có thể thấy sự chuyển dịch từ định tính sang định lượng thực chất là sự chuyển dịch từ việc xử lý thông tin mềm sang việc xử lý thông tin cứng, theo cách phân loại của Berger và Udell (2006). Thông tin cứng là những dữ liệu có thể được số hóa, lưu trữ, truyền tải và xử lý bởi máy tính mà không phụ thuộc vào ngữ cảnh hay người thu thập, chẳng hạn như điểm tín dụng, tỷ lệ nợ trên thu nhập hay báo cáo tài chính đã kiểm toán. Chính đặc tính có thể số hóa này đã tạo điều kiện cho phương pháp định lượng vượt qua giới hạn về quy mô vốn là nhược điểm cố hữu của phương pháp định tính, bởi một mô hình chấm điểm sau khi được xây dựng và kiểm định có thể được áp dụng đồng thời cho hàng triệu hồ sơ vay với chi phí biên gần như bằng không, trong khi một cán bộ tín dụng dù có kinh nghiệm đến đâu cũng chỉ có thể xử lý một số lượng hồ sơ giới hạn trong cùng một khoảng thời gian.

Chính khả năng mở rộng quy mô gần như vô hạn này là cơ sở để hiểu vì sao khái niệm công nghiệp hóa sự tin cậy lại trở nên thiết yếu trong kỷ nguyên tài chính số. Về bản chất, tín dụng luôn là một giao dịch dựa trên lòng tin, trong đó bên cho vay phải tin tưởng rằng bên vay sẽ hoàn trả nghĩa vụ trong tương lai dù không có sự bảo đảm tuyệt đối nào tại thời điểm hiện tại. Trong nền kinh tế truyền thống, lòng tin này được xây dựng thông qua các mối quan hệ trực tiếp, mang tính thủ công và cục bộ, tương tự như cách một ngân hàng địa phương hiểu rõ khách hàng của mình qua nhiều năm giao dịch. Tuy nhiên, khi tài chính số phát triển với đặc trưng là khối lượng giao dịch khổng lồ, tốc độ xử lý gần như tức thời và phạm vi hoạt động xuyên biên giới, mô hình xây dựng lòng tin dựa trên quan hệ cá nhân trở nên hoàn toàn bất khả thi về mặt vận hành. Philippon (2016), trong phân tích về vai trò của công nghệ tài chính, đã lập luận rằng các nền tảng cho vay số hóa và ứng dụng tài chính di động chỉ có thể tồn tại và mở rộng nếu quyết định tín dụng được tự động hóa hoàn toàn thông qua các thuật toán chấm điểm, bởi không một tổ chức nào có thể tuyển dụng đủ số lượng chuyên gia thẩm định để đánh giá thủ công hàng triệu yêu cầu vay mỗi ngày.

Nói cách khác, công nghiệp hóa sự tin cậy chính là quá trình chuyển hóa lòng tin từ một phẩm chất mang tính quan hệ cá nhân, vốn được tích lũy chậm và khó chuyển giao, thành một sản phẩm có thể sản xuất hàng loạt, chuẩn hóa và phân phối trên quy mô lớn thông qua thuật toán và dữ liệu. Quá trình này mang lại ba lợi ích thiết yếu đối với hệ thống tài chính số. Thứ nhất, nó giúp giảm chi phí giao dịch một cách đáng kể, vì việc ra quyết định tín dụng không còn phụ thuộc vào nguồn lực con người khan hiếm mà có thể được thực hiện tự động với chi phí biên cực thấp, từ đó cho phép các nền tảng tài chính số phục vụ cả những phân khúc khách hàng có giá trị giao dịch nhỏ mà mô hình thẩm định thủ công truyền thống không có động lực kinh tế để phục vụ. Thứ hai, nó tạo ra tính nhất quán và có thể kiểm chứng trong quyết định tín dụng, vì một mô hình chấm điểm được xây dựng dựa trên dữ liệu và kiểm định thống kê có thể được giải trình, kiểm tra và điều chỉnh một cách có hệ thống, khác với phán đoán chủ quan của từng cá nhân vốn khó tái lập và khó kiểm toán. Thứ ba, nó cho phép mở rộng phạm vi tiếp cận tín dụng tới những nhóm khách hàng trước đây bị loại trừ khỏi hệ thống tài chính chính thức do thiếu quan hệ cá nhân với ngân hàng, đặc biệt tại các thị trường mới nổi, thông qua việc sử dụng các nguồn dữ liệu thay thế như lịch sử giao dịch viễn thông, hành vi thanh toán hóa đơn hoặc dữ liệu thương mại điện tử để xây dựng hồ sơ tín dụng thay thế cho lịch sử vay ngân hàng truyền thống.

Tuy nhiên, cần nhìn nhận rằng sự chuyển dịch này không đồng nghĩa với việc yếu tố định tính hoàn toàn biến mất khỏi quy trình đánh giá tín dụng hiện đại. Thay vào đó, phần lớn các tổ chức tín dụng hiện nay áp dụng mô hình lai, trong đó chấm điểm định lượng đóng vai trò sàng lọc ban đầu trên diện rộng, còn phán đoán định tính của chuyên gia được giữ lại để xử lý các trường hợp biên, các hồ sơ phức tạp hoặc các khoản vay có giá trị lớn mà hậu quả sai lầm có thể rất nghiêm trọng. Điều này cho thấy công nghiệp hóa sự tin cậy trong tài chính số không phải là sự thay thế tuyệt đối con người bằng thuật toán, mà là một quá trình phân bổ lại vai trò, trong đó thuật toán đảm nhận việc xử lý khối lượng

lớn với tốc độ cao, còn con người tập trung vào những quyết định đòi hỏi mức độ phán đoán và trách nhiệm giải trình cao nhất.

PHẦN 2. KIỂM TRA VÀ XỬ LÝ DỮ LIỆU

2.1. Kiểm tra chất lượng dữ liệu

Rà soát tổng thể chất lượng dữ liệu thông qua kiểu dữ liệu của từng cột, tỷ lệ giá trị thiếu, số lượng giá trị duy nhất và số dòng trùng lặp hoàn toàn cho thấy tập Training có 44 dòng trùng lặp hoàn toàn và biến SEX thiếu khoảng 4,1% (1.106 dòng); tập OOS có 178 dòng trùng lặp và biến SEX thiếu khoảng 5,1% (1.277 dòng). Một phát hiện đáng chú ý là các cột số liên quan đến tiền tệ trong tập OOS (BASE_BAL, CURR_BAL, DUNO_QD, LAISUAT) đang được lưu dưới dạng chuỗi ký tự thay vì dạng số - đây là dấu hiệu ban đầu cho thấy dữ liệu OOS có lỗi định dạng cần được xử lý trước khi đưa vào mô hình.

2.2. Xử lý lỗi định dạng và lỗi logic nhập liệu

Lỗi dấu phẩy thập phân: chỉ xuất hiện ở tập OOS, các cột tiền tệ dùng dấu phẩy thay cho dấu chấm làm ký hiệu thập phân theo thói quen nhập liệu tiếng Việt (ví dụ "0,138"). Vấn đề được khắc phục bằng cách thay thế ký tự và ép kiểu về dạng số thực, áp dụng thống nhất cho cả ba tập dữ liệu để đảm bảo tính nhất quán.

Lỗi trộn lẫn định dạng ngày tháng: cột ngày mở vay và ngày đáo hạn chứa lẫn hai định dạng khác nhau, chuỗi ký tự dạng dd/mm/yyyy và số serial ngày theo chuẩn Excel (ví dụ số 40824 tương ứng với một ngày cụ thể). Một hàm chuyển đổi được xây dựng để tự động nhận diện kiểu dữ liệu của từng giá trị và quy đổi thống nhất về định dạng ngày tháng chuẩn.

Lỗi logic ngày mở vay sau ngày đáo hạn: đây là lỗi dữ liệu thực sự chứ không phải một quan sát cực trị nhưng đúng, do đó phương pháp log-transform (vốn chỉ phù hợp để nén thang đo cho giá trị đúng nhưng lệch) không được áp dụng. Thay vào đó, các dòng lỗi được gán cờ nhận diện và kỳ hạn vay được gán lại bằng giá trị trung vị hợp lệ, với ngưỡng hợp lệ (khoảng 365 đến 10.958 ngày, trung vị 1.461 ngày) chỉ được tính toán từ tập huấn luyện nhằm tránh rò rỉ thông tin sang tập kiểm định và tập OOS. Tỷ lệ lỗi phát hiện được là rất thấp ở tập Train và Test (dưới 0,1%) nhưng cao hơn đáng kể ở tập OOS (khoảng 0,4%, tương ứng 90 dòng).

Dòng trùng lặp hoàn toàn: chỉ được loại bỏ ở tập huấn luyện và tập kiểm định (phục vụ trực tiếp cho việc học mô hình), không loại bỏ ở tập OOS vì yêu cầu của bài toán là phải dự báo và xuất kết quả cho toàn bộ các dòng của OOS theo đúng thứ tự ban đầu để tiện đối chiếu sau này.

2.3. Xử lý dữ liệu thiếu


Biến duy nhất có tỷ lệ thiếu đáng kể là SEX (giới tính khách hàng). Phân tích sâu hơn theo loại khách hàng cho thấy SEX luôn bị bỏ trống khi khách hàng là doanh nghiệp (LOAIKH=2), điều này hoàn toàn hợp lý về mặt nghiệp vụ vì doanh nghiệp không có thuộc tính giới tính. Tuy nhiên, vẫn còn một bộ phận khách hàng cá nhân (LOAIKH=1) bị thiếu giá trị SEX, đây mới thực sự là trường hợp thiếu dữ liệu cần xử lý.

Ngoài ra, biến SEX còn tồn tại một vấn đề khác, cùng một ý nghĩa giới tính nhưng được ghi nhận theo hai chuẩn ký hiệu khác nhau - tiếng Việt (ONG/BA) và tiếng Anh (MR/MRS/MS). Nếu giữ nguyên hiện trạng, mô hình sẽ hiểu nhầm ONG và MR là hai hạng mục khác nhau dù cùng biểu thị nam giới, làm giảm chất lượng học của mô hình. Do đó, bước gộp chuẩn hóa về hai nhóm M/F được

thực hiện trước, sau đó giá trị thiếu được điền bằng nhãn "Unknown" thay vì loại bỏ dòng dữ liệu, nhằm giữ lại tối đa thông tin từ các biến khác của khách hàng.

2.4. Xử lý giá trị ngoại lai

Các biến phản ánh quy mô khoản vay (hạn mức gốc, dư nợ hiện tại, dư nợ quy đổi) có phân phối lệch phải rất mạnh, với một số ít khách hàng có dư nợ lớn gấp hàng trăm lần khách hàng thông thường. Điểm quan trọng trong xử lý ngoại lai của nghiên cứu này là áp dụng hai chiến lược khác nhau cho hai loại vấn đề có bản chất khác nhau.




Đối với các biến số dư/hạn mức, phương pháp log-transform ($\log1p$) được lựa chọn thay vì cắt ngưỡng phần trăm vị (winsorize), bởi vì các giá trị lớn ở đây phản ánh thực tế khách quan (khách hàng doanh nghiệp hoặc khoản vay lớn có tồn tại thật trong dữ liệu), không phải lỗi nhập liệu. Nếu áp dụng winsorize, hai khách hàng có dư nợ chênh lệch rất lớn (ví dụ 5 tỷ và 50 tỷ đồng) sẽ bị cắt về cùng một giá trị ngưỡng, làm mất đi thông tin phân biệt quan trọng giữa các khách hàng lớn. Log-transform chỉ nén thang đo mà vẫn giữ nguyên thứ tự và thông tin tương đối giữa các quan sát.

Ngược lại, đối với kỳ hạn vay - nơi giá trị bất thường (kỳ hạn âm hoặc kéo dài hàng trăm năm) là hệ quả trực tiếp của lỗi logic ngày mở vay sau ngày đáo hạn đã nêu ở mục 3.2 - bản thân giá trị đó là sai một cách khách quan chứ không phải một quan sát cực trị nhưng đúng. Với loại lỗi này, log-transform không thể sửa được bản chất sai của dữ liệu, nên phương pháp gán lại giá trị hợp lệ được sử dụng thay thế. Riêng biến lãi suất được kiểm tra và xác nhận nằm trong khoảng hợp lý (0% đến 40%), không có giá trị âm hay vượt quá 100%, nên không cần can thiệp thêm.

2.5. Xử lý mất cân bằng dữ liệu

Phân tích phân phối biến NHOMNO trên tập huấn luyện cho thấy mức độ mất cân bằng nghiêm trọng: nhóm 1 chiếm tới 79,1% tổng số quan sát, trong khi nhóm 3 chỉ chiếm 2,1%, tương ứng tỷ lệ mất cân bằng giữa lớp nhiều nhất và lớp ít nhất lên tới khoảng 38,3 lần. Nếu huấn luyện mô hình trực tiếp trên dữ liệu này mà không xử lý, mô hình sẽ có xu hướng luôn dự báo nghiêng về nhóm 1 để tối đa hóa độ chính xác tổng thể, trong khi bỏ qua khả năng phát hiện các nhóm nợ xấu.

Giải pháp được lựa chọn là sử dụng cơ chế trọng số lớp cân bằng ($\text{class_weight/sample_weight} = \text{"balanced"}$) trong quá trình huấn luyện, theo đó mỗi quan sát được gán một trọng số tỷ lệ nghịch với tần suất xuất hiện của lớp mà nó thuộc về, giúp mô hình chú ý nhiều hơn đến các lớp thiểu số mà không cần tạo ra dữ liệu giả. Phương pháp sinh mẫu tổng hợp SMOTE không được sử dụng vì dữ liệu có cả biến số lẫn biến hạng mục nhiều chiều sau khi mã hóa one-hot; việc nội suy tuyến tính giữa các điểm dữ liệu one-hot dễ tạo ra các bản ghi phi thực tế, chẳng hạn giá trị "lai" giữa hai sản phẩm vay khác nhau vốn không tồn tại trong thực tế.



PHẦN 3. XÂY DỰNG ĐẶC TRƯNG VÀ LỰA CHỌN BIẾN

3.1. Xây dựng biến mới

Dựa trên hiểu biết nghiệp vụ tín dụng, năm biến mới được xây dựng nhằm bổ sung thông tin dự báo cho mô hình. Biến UTILIZATION đo tỷ lệ dư nợ hiện tại trên hạn mức gốc, phản ánh mức độ sử dụng hạn mức tín dụng - khách hàng sử dụng gần hết hoặc vượt hạn mức thường tiềm ẩn rủi ro cao hơn. Biến IS_FX đánh dấu khoản vay bằng ngoại tệ. Biến IS_ZERO_RATE đánh dấu khoản vay có lãi suất bằng 0, thường là sản phẩm ưu đãi đặc biệt. Biến MUCDICHVAY_GROUP nhóm các mã mục đích vay chi tiết (khoảng 40 mã) thành các nhóm lớn hơn dựa trên hai chữ số đầu của mã, nhằm giảm số chiều dữ liệu. Cuối cùng, biến OPEN_YEAR trích xuất năm mở khoản vay để mô hình có thể nắm bắt xu hướng biến động theo thời gian.

3.2. Mã hóa biến hạng mục

Chiến lược mã hóa được lựa chọn tùy theo số lượng hạng mục của từng biến. Đối với các biến có ít hạng mục (loại tài khoản, giới tính đã chuẩn hóa, loại khách hàng, thời hạn mô tả, nhóm mục đích vay), phương pháp One-Hot Encoding được áp dụng trực tiếp trong pipeline mô hình. Đối với các biến có số lượng hạng mục lớn (mã chi nhánh, mã chi nhánh cấp trên, mã sản phẩm chi tiết, mã mục đích vay chi tiết), One-Hot Encoding sẽ tạo ra quá nhiều cột thừa và không hiệu quả, nên phương pháp Frequency Encoding được sử dụng thay thế, trong đó mỗi mã được thay bằng tần suất xuất hiện của nó. Một điểm cần lưu ý về mặt phương pháp luận là tần suất được tính toán trên tập hợp gộp của cả Training và OOS, nhưng chỉ sử dụng giá trị của biến độc lập, hoàn toàn không sử dụng nhãn mục tiêu nên không xảy ra rò rỉ thông tin nhãn. Cách làm này giúp tránh trường hợp một mã sản phẩm hiếm gặp trong tập Training nhưng phổ biến trong tập OOS (hoặc ngược lại) bị mã hóa sai lệch, dẫn đến mô hình suy diễn nhầm khi áp dụng cho dữ liệu mới.

3.3. Lựa chọn biến

Hai phương pháp bổ trợ nhau được sử dụng để đánh giá sức mạnh dự báo của từng biến. Phương pháp thứ nhất là Mutual Information, đo lượng thông tin chung giữa biến độc lập và biến mục tiêu NHOMNO mà không cần giả định quan hệ tuyến tính, phù hợp với bản chất có thể phi tuyến giữa các biến đầu vào và nhóm nợ. Phương pháp thứ hai là chỉ số WOE/IV (Weight of Evidence/Information Value), đo sức phân tách giữa nhóm "nợ tốt" và "nợ xấu", trong đó nợ xấu được định nghĩa là NHOMNO từ 3 trở lên theo đúng chuẩn phân loại nợ của Ngân hàng Nhà nước.


Kết quả từ cả hai phương pháp đồng thuận cho thấy nhóm biến có sức dự báo mạnh nhất bao gồm tần suất mã sản phẩm chi tiết, lãi suất, kỳ hạn vay, tỷ lệ sử dụng hạn mức, tần suất mục đích vay, năm mở khoản vay và loại tài khoản. Giá trị IV đo được ở mức khá cao so với ngưỡng tham khảo thông thường, một phần do dữ liệu mất cân bằng nặng khiến một số phân khúc (bin) có rất ít quan sát ở nhóm thiểu số, vì vậy các con số IV cần được diễn giải một cách thận trọng, không tuyệt đối hóa. Toàn bộ 19 biến đã xây dựng được giữ lại cho bước mô hình hóa, không loại bỏ thêm, vì số lượng biến còn khá gọn và các mô hình cây/boosting ở phần sau có khả năng tự động hạ trọng số các biến ít hữu ích.

Một bước kiểm tra quan trọng khác là phân tích đa cộng tuyến, đặc biệt cần thiết đối với các mô hình tuyến tính. Kết quả cho thấy hai biến phản ánh dư nợ hiện tại và dư nợ quy đổi có tương quan gần như tuyệt đối (hệ số tương quan xấp xỉ 1,0), do bản chất dư nợ quy đổi bằng dư nợ hiện tại đối với mọi khoản vay bằng đồng Việt Nam, chỉ khác biệt khi khoản vay là ngoại tệ. Để tránh vấn đề đa cộng tuyến, biến dư nợ quy đổi được loại khỏi tập biến số dùng cho các mô hình tuyến tính (Logistic Regression, LDA, QDA), trong khi vẫn được giữ lại cho các mô hình cây vốn không bị ảnh hưởng bởi hiện tượng này. Kết quả là hai bộ tiền xử lý dữ liệu riêng biệt được xây dựng: một bộ đầy đủ 19 biến cho các mô hình cây/boosting, và một bộ 13 biến (đã loại biến trùng lặp thông tin) cho các mô hình tuyến tính, cả hai đều chỉ được huấn luyện (fit) trên tập dữ liệu train để đảm bảo tính khách quan khi đánh giá.

PHẦN 4. XÂY DỰNG VÀ SO SÁNH CÁC MÔ HÌNH


4.1. Nhóm mô hình truyền thống

Nhóm mô hình đầu tiên gồm các phương pháp thống kê/tham số cổ điển, được sử dụng phổ biến trong chấm điểm tín dụng nhờ tính đơn giản, ổn định và khả năng diễn giải cao - một yếu tố quan trọng khi cần giải trình với bộ phận quản trị rủi ro hoặc kiểm toán nội bộ. Mô hình Logistic Regression là phương pháp hồi quy tuyến tính cho bài toán phân loại, có ưu điểm là hệ số hồi quy có thể diễn giải trực tiếp thông qua tỷ số chênh (odds ratio). Mô hình Decision Tree xây dựng một cây quyết định đơn với độ sâu tối đa được giới hạn ở 6 để tránh hiện tượng quá khớp (overfitting) - vấn đề đặc biệt nghiêm trọng khi các lớp thiểu số chỉ có vài trăm quan sát. Cuối cùng, hai mô hình phân tích biệt thức LDA và QDA dựa trên giả định phân phối Gauss của các biến trong từng lớp: LDA giả định các lớp có chung một ma trận hiệp phương sai (cho ranh giới phân loại tuyến tính, ổn định hơn khi dữ liệu ít), trong khi QDA cho phép mỗi lớp có ma trận hiệp phương sai riêng (ranh giới cong, linh hoạt hơn nhưng cần ước lượng nhiều tham số hơn).



4.2. Nhóm mô hình phi truyền thống

Nhóm mô hình thứ hai gồm các phương pháp ensemble hiện đại, thường đạt độ chính xác cao hơn nhờ khả năng nắm bắt quan hệ phi tuyến và tương tác phức tạp giữa các biến, đánh đổi bằng việc khó diễn giải trực tiếp hơn (cần công cụ hỗ trợ như SHAP ở phần sau). XGBoost là thuật toán gradient boosting xây dựng tuần tự nhiều cây quyết định, trong đó mỗi cây sau được huấn luyện để sửa lỗi của các cây trước đó. LightGBM thuộc cùng họ gradient boosting nhưng sử dụng chiến lược mọc cây theo lá (leaf-wise) thay vì theo tầng (level-wise), thường cho tốc độ huấn luyện nhanh hơn với dữ liệu lớn. Random Forest sử dụng chiến lược bagging, xây dựng nhiều cây độc lập trên các mẫu con ngẫu nhiên rồi lấy trung bình kết quả để giảm phương sai, được dùng làm mô hình đối chứng cho hai phương pháp boosting nêu trên.




4.3. So sánh hiệu suất mô hình

Để so sánh khách quan hiệu suất của bảy mô hình trên, bốn chỉ số được sử dụng trên tập kiểm định. Accuracy (độ chính xác tổng thể) dễ hiểu nhưng không đáng tin cậy khi dữ liệu mất cân bằng, bởi một mô hình luôn đoán nhóm 1 vẫn có thể đạt accuracy xấp xỉ 79%. F1-macro, tính bằng trung bình cộng không trọng số của F1-score trên cả năm nhóm nợ, phản ánh đúng khả năng phát hiện cả các nhóm thiểu số và được chọn làm chỉ số chính để so sánh. AUC (diện tích dưới đường ROC, tính theo phương pháp One-vs-Rest và lấy trung bình macro) đo khả năng phân tách giữa các lớp không phụ thuộc ngưỡng phân loại. Gini, bằng hai lần AUC trừ một, là chỉ số quen thuộc trong ngành ngân hàng, có cùng ý nghĩa với AUC nhưng thang đo quen thuộc hơn với bộ phận quản trị rủi ro.

Kết quả so sánh chi tiết được trình bày trong bảng dưới đây, sắp xếp theo thứ tự F1-macro giảm dần:

Mô hình	Accuracy	F1-macro	AUC	Gini
LightGBM	0,8067	0,5494	0,9244	0,8488
XGBoost	0,7845	0,5417	0,9238	0,8476
Random Forest	0,6707	0,5095	0,9037	0,8073

Decision Tree	0,6420	0,4929	0,9012	0,8024
Logistic Regression	0,6116	0,4106	0,8249	0,6498
LDA	0,6225	0,3818	0,7769	0,5539
QDA	0,5096	0,3713	0,8021	0,6042



Kết quả cho thấy nhóm mô hình học máy hiện đại (XGBoost, LightGBM, Random Forest) vượt trội hoàn toàn so với nhóm mô hình thống kê truyền thống ở cả hai chỉ số F1-macro và Gini, phản ánh việc dữ liệu tồn tại các tương tác phi tuyến giữa loại sản phẩm, kỳ hạn và lãi suất mà các mô hình tuyến tính như Logistic Regression hay LDA khó nắm bắt đầy đủ. Trong nhóm mô hình truyền thống, QDA có hiệu suất thấp nhất, chủ yếu do vấn đề ước lượng ma trận hiệp phương sai riêng cho từng lớp trở nên kém ổn định khi một số lớp có ít quan sát, dù đã áp dụng kỹ thuật chính quy hóa (regularization). Dựa trên kết quả này, mô hình truyền thống tốt nhất (Decision Tree, F1-macro = 0,4929) và mô hình hiện đại tốt nhất (LightGBM, F1-macro = 0,5494) được chọn để tiếp tục tinh chỉnh siêu tham số ở bước tiếp theo.


4.4. Tinh chỉnh siêu tham số

Phương pháp RandomizedSearchCV với 3-fold cross-validation, tối ưu theo chỉ số F1-macro, được áp dụng để tinh chỉnh siêu tham số cho hai mô hình đã chọn. Nguyên tắc quan trọng được tuân thủ xuyên suốt là sau khi tuning, kết quả phải được so sánh lại trên tập kiểm định độc lập, và chỉ chấp nhận bộ tham số mới nếu nó thực sự cải thiện F1-macro trên tập này - bởi lẽ RandomizedSearchCV chỉ tối ưu theo điểm cross-validation nội bộ trên tập train, không đảm bảo luôn tốt hơn trên tập test độc lập do phương sai giữa các fold hoặc không gian tìm kiếm chưa phù hợp.


Đối với Logistic Regression, siêu tham số chính được tinh chỉnh là hệ số C (nghịch đảo cường độ chính quy hóa L2). Kết quả tìm kiếm cho giá trị tối ưu $C = 3$, nhưng F1-macro sau tuning (0,4103) không cải thiện so với trước tuning (0,4106), nên mô hình cơ sở (baseline) được giữ lại. Đối với XGBoost, sáu siêu tham số được tinh chỉnh đồng thời gồm số lượng cây, độ sâu tối đa, tốc độ học, tỷ lệ mẫu con, tỷ lệ biến con và trọng số tối thiểu của node con. Kết quả tuning cải thiện rõ rệt F1-macro từ 0,5417 lên 0,5663, do đó bộ tham số mới được chấp nhận và sử dụng cho bước dự báo tiếp theo.

Sự khác biệt về kết quả tuning giữa hai mô hình có thể được giải thích như sau: khi tuning cải thiện hiệu suất (trường hợp XGBoost), nguyên nhân thường là do bộ tham số mặc định ban đầu chưa tối ưu độ sâu và tốc độ học cho đặc thù dữ liệu mất cân bằng của bài toán. Ngược lại, khi tuning không cải thiện (trường hợp Logistic Regression), nguyên nhân thường nằm ở việc RandomizedSearchCV tối ưu theo điểm trung bình cross-validation trên tập train, trong khi các lớp thiểu số có quá ít mẫu khiến điểm số giữa các fold dao động mạnh, dẫn đến bộ tham số "tốt nhất theo CV" chưa chắc tổng quát hóa tốt nhất trên tập kiểm định độc lập. Đây chính là lý do nguyên tắc đối chiếu lại trên tập test luôn được áp dụng thay vì mặc định tin tưởng hoàn toàn vào kết quả tìm kiếm siêu tham số.

Confusion Matrix - Logistic Regression (tuned)



Confusion Matrix - XGBoost (tuned)



PHẦN 5. DỰ BÁO NGOÀI MẪU VÀ GIẢI THÍCH BẰNG SHAP


5.1. Dự báo ngoài mẫu

Theo kết quả so sánh, nhóm mô hình học máy hiện đại vượt trội nhóm truyền thống. Trong nhóm này, sau khi tinh chỉnh, XGBoost đạt F1-macro 0,5663, cao hơn so với LightGBM ở mức baseline (0,5494). Mô hình production được lựa chọn theo cơ chế động, dựa trên F1-macro đo được thực tế giữa hai ứng viên hàng đầu thay vì cố định cứng một thuật toán, nhằm đảm bảo luôn chọn đúng mô hình tốt nhất kể cả khi kết quả có thể xê dịch nhẹ giữa các lần chạy hoặc các phiên bản thư viện khác nhau. Kết quả cuối cùng, XGBoost (đã tinh chỉnh) được chọn làm mô hình production.

Vì bài toán yêu cầu dự báo đồng thời hai biến mục tiêu có quan hệ ràng buộc lẫn nhau (NHOMNO và NHOMNOMOI, trong đó nhóm nợ mới về nguyên tắc nghiệp vụ không thể tốt hơn nhóm nợ hiện tại), một chiến lược dự báo hai giai đoạn được thiết kế. Ở giai đoạn A, mô hình dự báo NHOMNO trực tiếp từ 19 đặc trưng gốc. Ở giai đoạn B, mô hình dự báo NHOMNOMOI từ cùng bộ đặc trưng gốc cộng thêm biến NHOMNO làm đầu vào bổ sung, khi huấn luyện sử dụng giá trị NHOMNO thực tế, còn khi dự báo cho tập OOS thì sử dụng giá trị NHOMNO đã được dự báo ở giai đoạn A. Cuối cùng, một ràng buộc hậu xử lý được áp dụng: nếu mô hình dự báo NHOMNOMOI nhỏ hơn NHOMNO (vi phạm quy luật nghiệp vụ), giá trị NHOMNOMOI sẽ được ép lại bằng giá trị lớn hơn giữa hai dự báo. Trước khi thực hiện dự báo trên tập OOS, mô hình được huấn luyện lại trên toàn bộ dữ liệu có nhãn (gộp cả tập train và test) nhằm tận dụng tối đa lượng dữ liệu sẵn có, vì tập test đã hoàn thành vai trò đánh giá ở các bước trước.

Kết quả dự báo giai đoạn A cho thấy phân phối các nhóm nợ trên tập OOS lệch khá xa so với phân phối thực tế trên tập Training: trong khi nhóm 1 chiếm tới 79,1% ở tập Training, tỷ lệ dự báo nhóm 1 trên OOS chỉ còn khoảng 23,5%, trong khi nhóm 4 chiếm tới 51,6% dự báo. Sau khi áp dụng ràng buộc nghiệp vụ ở giai đoạn B, số dòng vi phạm quy tắc NHOMNOMOI nhỏ hơn NHOMNO trước

khi hiệu chỉnh là 0, cho thấy mô hình đã tự học được quy luật này một cách tự nhiên từ dữ liệu huấn luyện mà không cần can thiệp nhiều.





Để lý giải hiện tượng lệch phân phối nêu trên, tiếp tục kiểm tra độ lệch phân phối biến đầu vào (covariate shift) giữa tập Training và tập OOS. Kết quả phân tích cơ cấu sản phẩm vay cho thấy sự khác biệt rất rõ rệt: sản phẩm vay tiêu dùng (CNS), vốn chiếm tới 82,5% ở tập Training, chỉ còn chiếm 32,9% ở tập OOS; ngược lại, sản phẩm vay thế chấp (MTG) tăng từ 9,3% lên 46,0%, và sản phẩm vay thương mại (CML) tăng từ 8,2% lên 21,1%. Sự khác biệt lớn về cơ cấu sản phẩm này là nguyên nhân chính khiến kết quả dự báo trên OOS lệch xa so với phân phối gốc của tập huấn luyện, đồng thời cũng là cơ sở để khuyến nghị rằng kết quả dự báo cho các khoản vay thuộc nhóm sản phẩm thế chấp và thương mại trên tập OOS cần được diễn giải một cách thận trọng hơn, do mô hình được huấn luyện chủ yếu trên dữ liệu vay tiêu dùng. Kết quả dự báo cuối cùng được xuất ra tập CSV, giữ nguyên toàn bộ các cột gốc của tập OOS đồng thời bổ sung hai cột dự báo mới, và đặc biệt giữ nguyên thứ tự dòng ban đầu để thuận tiện cho việc đối chiếu với nhãn thực tế trong tương lai nếu có.

5.2. Giải thích bằng SHAP

Do các mô hình ensemble như XGBoost có tính chất "hộp đen", khó diễn giải trực tiếp qua hệ số như mô hình tuyến tính, phương pháp SHAP (SHapley Additive exPlanations) được sử dụng để định lượng mức độ đóng góp của từng biến đến kết quả dự báo. Cụ thể, bộ giải thích TreeExplainer được áp dụng cho mô hình production (XGBoost, giai đoạn A), với một mẫu 3.000 quan sát được lấy ngẫu nhiên để tính toán nhanh hơn mà vẫn đảm bảo ước lượng ổn định, không cần thiết phải sử dụng toàn bộ dữ liệu. Để làm rõ không chỉ mức độ quan trọng mà cả chiều tác động của từng biến, giá trị SHAP có dấu (không lấy trị tuyệt đối) được phân tích cho lớp NHOMNO = 1 ("không nợ xấu"), SHAP dương nghĩa là biến đó kéo xác suất về phía nhóm 1 (giảm rủi ro nợ xấu), SHAP âm nghĩa là biến đó đẩy xác suất khỏi nhóm 1 (tăng rủi ro nợ xấu). Chiều tác động của mỗi biến được xác định bằng hệ số tương quan giữa giá trị biến và giá trị SHAP tương ứng trên mẫu 3.000 quan sát. Kết quả xếp hạng mười biến quan trọng nhất theo giá trị SHAP tuyệt đối trung bình được trình bày trong bảng sau:

Hạng	Biến	Mean SHAP	Tương quan (giá trị biến ↔ SHAP)	Chiều tác động lên rủi ro nợ xấu
1	OPEN_YEAR (năm mở khoản vay)	0,964	+0,80 (mạnh)	Khoản vay mở càng gần đây → rủi ro nợ xấu càng thấp
2	UTILIZATION (tỷ lệ sử dụng hạn mức)	0,926	-0,08 (yếu, phi tuyến)	Tỷ lệ sử dụng hạn mức càng cao → rủi ro nợ xấu càng cao
3	TENOR_YEARS (kỳ hạn vay)	0,866	+0,53 (mạnh)	Kỳ hạn càng dài → rủi ro nợ xấu càng thấp

Hạng	Biến	Mean SHAP	Tương quan (giá trị biến ↔ SHAP)	Chiều tác động lên rủi ro nợ xấu
4	LOG_CURR_BAL (dư nợ hiện tại)	0,607	-0,36 (trung bình)	Dư nợ hiện tại càng lớn → rủi ro nợ xấu càng cao
5	ORGNBR_FREQ (tần suất chi nhánh)	0,487	+0,10 (yếu)	Chi nhánh có quy mô/tần suất giao dịch càng lớn → rủi ro thấp hơn một chút
6	LOG_BASE_BAL (hạn mức gốc)	0,412	-0,29 (trung bình)	Hạn mức cấp ban đầu càng lớn → rủi ro nợ xấu càng cao
7	LAISUAT (lãi suất)	0,406	-0,66 (mạnh)	Lãi suất càng cao → rủi ro nợ xấu càng cao
8	CURRMICCTT YPCD_FREQ (tần suất mã sản phẩm)	0,386	+0,24 (yếu-TB)	Sản phẩm càng phổ biến → rủi ro thấp hơn
9	PARENTORGNBR_FREQ (tần suất chi nhánh cấp trên)	0,377	+0,28 (yếu-TB)	Cụm chi nhánh cấp trên càng lớn → rủi ro thấp hơn một chút
10	MUCDICHVAY_FREQ (tần suất mục đích vay)	0,131	-0,06 (rất yếu)	Ảnh hưởng không đáng kể, gần như nhiều



Diễn giải theo 3 nhóm biến:

(1) Nhóm biến thời gian/tuổi khoản vay OPEN_YEAR, TENOR_YEARS (hạng 1 và 3): Đây là hai biến có tác động mạnh nhất và cùng chiều dương với xác suất "không nợ xấu". OPEN_YEAR mang tính chất seasoning: khoản vay mở càng gần đây càng chưa có đủ thời gian để phát sinh nợ quá hạn tại thời điểm quan sát dữ liệu, nên xuất hiện là "tốt" mang tính hiệu ứng thời gian quan sát (right-censoring) hơn là bản chất rủi ro thực sự thấp hơn. TENOR_YEARS cho thấy kỳ hạn càng dài thì rủi ro nợ xấu càng thấp (tương quan +0,53). Nguyên nhân nhiều khả năng đến từ cơ cấu sản phẩm: các khoản vay kỳ hạn dài trong bộ dữ liệu này chủ yếu là vay thế chấp (MTG) có tài sản bảo đảm và quy trình thẩm định chặt chẽ hơn, trong khi vay tiêu dùng (CNS) kỳ hạn ngắn nhưng lại chiếm tỷ trọng nợ xấu cao hơn.

(2) Nhóm biến rủi ro tài chính trực tiếp UTILIZATION, LOG_CURR_BAL, LOG_BASE_BAL, LAISUAT (hạng 2, 4, 6, 7): Cả bốn biến đều tác động cùng chiều làm tăng rủi ro nợ xấu khi giá trị tăng, đúng với lý thuyết quản trị rủi ro tín dụng kinh điển. LAISUAT có tương quan âm mạnh nhất trong nhóm này (-0,66), phù hợp với cơ chế định giá theo rủi ro (risk-based pricing), khách hàng rủi ro cao hơn thường bị áp lãi suất cao hơn ngay từ khâu thẩm định ban đầu, và mô hình "học lại" đúng mối quan hệ này từ dữ liệu. UTILIZATION có tương quan tuyến tính yếu (-0,08) nhưng khi tách theo nhóm dưới/trên trung vị thì SHAP trung bình giảm rõ rệt (từ +0,59 xuống +0,07), cho thấy quan hệ phi tuyến, rủi ro tăng vọt khi khách hàng tiệm cận hoặc vượt hạn mức, đúng bản chất chỉ báo cảnh báo sớm (early-warning indicator) chứ không tăng đều đặn theo tỷ lệ sử dụng.

(3) Nhóm biến tần suất/kênh phân phối ORGNBR_FREQ, CURRMIACTTYP_CD_FREQ, PARENTORGNBR_FREQ, MUCDICHVAY_FREQ (hạng 5, 8, 9, 10): Cả bốn biến này đều mang tác động cùng chiều nhưng yếu hơn nhiều so với hai nhóm trên (tương quan 0,10-0,28, riêng MUCDICHVAY_FREQ gần như không đáng kể ở mức 0,131 mean|SHAP|). Xu hướng chung: chi nhánh/sản phẩm/mục đích vay càng phổ biến (tần suất cao) thì rủi ro càng thấp, có thể phản ánh việc các kênh/sản phẩm chủ lực được chuẩn hóa quy trình thẩm định tốt hơn, trong khi các mã hiếm gặp có thể là trường hợp đặc thù, ít được kiểm soát chuẩn hóa. Do mức ảnh hưởng khiêm tốn, nhóm biến này nên được xem là yếu tố hỗ trợ chứ không phải động lực chính của mô hình.

5/10 biến quan trọng nhất (UTILIZATION, LOG_CURR_BAL, LOG_BASE_BAL, LAISUAT, và một phần MUCDICHVAY_FREQ) làm tăng rủi ro khi giá trị tăng; trong khi 2 biến có ảnh hưởng mạnh nhất (OPEN_YEAR, TENOR_YEARS) lại có chiều tác động giảm rủi ro khi giá trị tăng, phần lớn do đặc thù cấu trúc dữ liệu (seasoning và cơ cấu sản phẩm) hơn là quan hệ nhân quả rủi ro-thời gian thuần túy.

TÀI LIỆU THAM KHẢO

- [1] F. S. Mishkin, *The Economics of Money, Banking, and Financial Markets* (11th ed.), Pearson, 2016.
- [2] P. S. Rose and S. C. Hudgins, *Bank Management & Financial Services* (9th ed.), McGraw-Hill, 2013.
- [3] A. N. Berger and G. F. Udell, "A more complete conceptual framework for SME finance," *Journal of Banking & Finance*, vol. 30, no. 11, pp. 2945-2966, 2006.
- [4] M. A. Petersen and R. G. Rajan, "The benefits of lending relationships: Evidence from small business data.," *The Journal of Finance*, vol. 49, no. 1, pp. 3-37, 1994.
- [5] T. Philippon, "The FinTech opportunity (NBER Working Paper No. 22476). National Bureau of Economic Research.," 2016.
- [6] L. C. Thomas, D. B. Edelman and J. N. Crook, "Credit scoring and its applications," *Society for Industrial and Applied Mathematics*, 2002.